

18/02/2022

TD3: Optimisation de requêtes

Exercice 3: Jointures entre 2 relations (p114)

$R(a,b)$ $S(c)$
Requête: $A = \sigma_{b=1} (R \bowtie_{a=c} S)$

- $P_1 = A$ 
- $P_2 = [\sigma_{b=1}(R)] \bowtie_{a=c} S$, avec la commutativité de la jointure.
- $P_3 = \sigma_{b=1} (S \bowtie_{a=c} R)$
- $P_4 = S \bowtie [\sigma_{b=1}(R)]$.

1) index sur $R.a$ et un index sur $R.b$

pour P_1 , aucun index utile

→ jointure par hachage: P_{1a}

$$\text{coût}(P_{1a}) = \text{coût}(\sigma_{b=1}(R \bowtie_{a=c} \text{Hachage } S))$$

$$= \text{coût}(R \bowtie_{a=c} \text{Hachage } S)$$

$$= \text{coût}(R) + \text{coût}(S) \leftarrow \text{voir page 12. (Notations et conventions).}$$

$$= P(R) + P(S)$$

• jointure par hachage et lecture séquentiel.

$$= 500 + 10 = 510$$

→ jointure par NL (boucle imbriquée): P_{1b}

$$\text{coût}(P_{1b}) = \text{coût}(R \bowtie_{a=c}^{\text{NL}} S)$$

$$= \text{coût}(R) + P(R) \times P(S) \rightarrow (\text{jointure par boucles imbriquées p12}).$$

$$= P(R) + P(R) \times P(S) = 500 + 500 \times 10 = 5500$$

Pour P_2 : utilise l'index $R.b$

• Par hachage: P_{2a}

$$\text{coût}(P_{2a}) = \text{coût}(\sigma_{b=1}(R)) + \text{coût}(S) \quad (\text{J4 page 12}).$$

$$= \text{card}(\sigma_{b=1}(R)) + P(S)$$

$$= \text{card}(R) \times \frac{1}{10 \text{ valeurs distinctes}} + P(S)$$

$$= 1000 \times \frac{1}{10} + 10 = 110$$

• Par NL: P_{2b}

$$\text{coût}(P_{2b}) = \text{coût}(\sigma_{b=1}(R)) + P(\sigma_{b=1}(R)) \times P(S)$$

$$= \text{card}(\sigma_{b=1}(R)) + P(R) \times \frac{1}{10} \times P(S)$$

$$\text{on a } \frac{\text{card}(R)}{\text{page}(R)} = \frac{\text{card}(\sigma_{b=1}(R))}{\text{page}(\sigma_{b=1}(R))}$$

car une sélection ne modifie pas la taille d'un tuple.

$$\begin{aligned}\text{coût}(P_{2b}) &= 100 + 500 \times \frac{1}{10} \times 10 \\ &= 100 + 50 \times 10 \\ &= 600.\end{aligned}$$

P3a par NL, utilise l'index R.a

$$\begin{aligned}\text{coût}(P_{3a}) &= \text{coût}(S \bowtie_{NL} R) \\ &= \text{coût}(S) + \text{card}(S) + \text{card}(\sigma_{a=x}(R)) \downarrow J1. \\ &= P(S) + \text{card}(S) \times \text{card}(R) \times \frac{1}{1000} \\ &= 10 + 100 \times 1 = 110 \quad // \text{ lorsque il y'a hachage l'index ne sert à rien.}\end{aligned}$$

P3b par hachage, sans index

$$\begin{aligned}\text{coût}(P_{3b}) &= \text{coût}(S) + \text{coût}(R) \\ &= P(S) + P(R) = 510.\end{aligned}$$

P4: la branche de droite utilise R.b.

remq: dans NL c'est la branche de droite de la jointure qui utilise l'index et non la branche de gauche.

P4a: jointure par hachage

$$\begin{aligned}\text{coût}(P_{4a}) &= \text{coût}(S) + \text{coût}(\sigma_{b=1}(R)) \\ &= P(S) + \text{card}(\sigma_{b=1}(R)) \\ &= 10 + 100 = 110.\end{aligned}$$

P4b: jointure par NL:

on pose $T_1 = \sigma_{b=1}(R)$.

on matérialise le résultat intermédiaire T_1 pour éviter de la redondance.

Voir la formule (J3) page 12.

$$\begin{aligned}\text{coût}(P_{4b}) &= \text{coût}(T_1) + P(T_1) + \text{coût}(S) + P(S) \times P(T_1) \\ &= \text{card}(T_1) + \frac{P(R)}{10} + P(S) \times \frac{P(R)}{10} \\ &= 100 + 50 + 10 + 10 \times 50 = 660\end{aligned}$$

② index S.c.

P1b: jointure NL avec index S.c.

$$\begin{aligned}\text{coût}(P_{1b}) &= P(R) + \text{card}(R) \times \text{card}(\sigma_{c=?}(S)) \quad \text{nb distinct de c} \\ &= 500 + 1000 \times 100 \times \frac{1}{100} \\ &= 1500\end{aligned}$$

• P1a par hachage? sans index $\longrightarrow$ coût(P_{1a}) = 510 cf 1)

• P2b jointure par NL

$$\begin{aligned}\text{coût}(P_{2b}) &= \text{coût}(\sigma_{b=1}(R)) + \text{card}(\sigma_{b=1}(R)) \times \text{card}(\sigma_{c=?}(S)) \\ &\quad \text{formule 83 car pas d'index sur S.b} \quad \downarrow \quad \downarrow \\ &= P(R) + 100 \times 1 \\ &= 500 + 100 \\ &= 600\end{aligned}$$

- P_3 ne peut pas utiliser l'index S.c car S est à gauche.
si pas d'index $\rightarrow$ faire du hachage.
 P_{3a} par hachage.

- P_4 : ne peut pas utiliser l'index S.c car S est à gauche.
 P_{4a} par hachage.
 $\text{coût}(P_{4a}) = \text{coût}(S) + \text{coût}(\tau_{b=1}(R))$
 $= P(S) + P(R) = 510.$

- ③ seulement l'index R.b et S.c.
 $P_2 + R.b$ est utilisé pour la sélection.
S.c est utilisé car S est sur la branche droite de R.

P_{2b} par NL : utilise R.b et S.c.

$$\begin{aligned}\text{coût}(P_{2b}) &= \text{coût}(\tau_{b=1}(R)) + \text{card}(\tau_{b=1}(R)) \times \text{card}(\tau_{c=?}(S)) \\ &= \text{card}(\tau_{b=1}(R)) + \text{card}(\tau_{b=1}(R)) \times \text{card}(\tau_{c=?}(S)) \\ &= \underset{100}{\downarrow} + \underset{100}{\downarrow} \times 1 = 200.\end{aligned}$$

Exercice 08: (ref ER1-19-2): Optimisation de requêtes.

①) S_1 : $\text{note} > 12$ AND $\text{note} \leq 17$ $SF_i(S_1) = \frac{\text{nb de valeurs}}{\text{nb de valeurs}} = \frac{17-12}{20} = \frac{5}{20}$
facteur de sélectivité $\downarrow$
 $\hookrightarrow [0, 20]$

S_2 : lieu IN ('Paris', 'Aix', 'Pau', 'Toul') $SF_i = \frac{4}{100}$

S_3 : $nE = 'E13'$ AND spécialité = 'ia' $SF_i = \frac{1}{1000} \times \frac{1}{8}$

S_4 : durée = 6 OR durée = 12 OR note > 5 $SF_i = \frac{2}{4} + \frac{15}{20} - \left(\frac{2}{4} \times \frac{20-5}{20}\right)$
plage $\frac{2}{4}$ $= \frac{5}{4} - \left(\frac{3}{8}\right) = \frac{7}{8}$

25/02/2022 suite

question 2: $\text{card}(R_1)$?

$R_1 = T_1 \bowtie_{nf} T_2$

avec T_1 : $\tau_{\text{mention}} = B$ (Elève)

T_2 : $\tau_{\text{région}} = 'idf'$ (Formation)

$\text{card}(T_1) = \text{card}(Elu) \times \frac{1}{4 \text{ mentions distinctes}}$

$\text{card}(T_2) = \text{card}(\text{Formation}) \times \frac{1}{5 \text{ régions}} = \frac{50}{5} = 10.$

Diapo 30 p 28

$$\text{card}(R_1) = \text{card}(T_1) \times \text{card}(T_2) \times \frac{1}{50} \text{ nF distincts.}$$

$$= 250 \times 10 \times 1/50 = 50.$$

$$R_2: \text{card}(E \bowtie_{nE} S \bowtie_{nF} F) = \text{card}(E \bowtie_{nE} S) \times \text{card}(F) \times \frac{1}{50} \text{ nF distincts.}$$

$$= \text{card}(E) \times \text{card}(S) \times \frac{1}{1000 \text{ nF distincts}} \times \text{card}(F) \times \frac{1}{50}.$$

$$\text{card}(R_2) = 1000 \times 2000 \times \frac{1}{1000} \times 50 \times \frac{1}{50} = 2000.$$

$$R_3: \text{card}(S \bowtie_{nE} PL) = 2000 \times 300 \times \frac{1}{1000} \text{ nF distincts.}$$


→ domaine de nE dans Etudiant.

Question 3:

Plan de requête avec un ordre tq on peut utiliser l'index Formation (nF).


$$\text{Essai: } \Pi \text{ mention } \left(\sigma_{\text{mention} = TB} (E) \bowtie_{nF} \sigma_{\text{diplôme} = \text{'Master'}} (F) \right).$$

Plan P1




n'utilise pas l'index Formation (nF)

Pour utiliser l'index il faut avoir Formation à droite de la jointure.



Dans P3, on n'utilise pas l'index formation (nF).




Coût du plan P2:

$$\text{coût}(P_2) = \text{coût}(E \bowtie F)$$


$$= \underbrace{\text{coût}(E)}_{\frac{\text{card}(E)}{10} = \frac{1000}{10}} + \underbrace{\text{card}(E)}_{1000} \times \underbrace{\text{coût}(\sigma_{\text{diplôme} = \text{'Master'}}(F))}_{\frac{\text{card}(F)}{50} \times \frac{1}{50}}$$

Question 4:

a) Motif attendu



si on combine ces deux la, où placer les 2 selections manquantes?



$$\text{coût}(T_1) = \text{coût}(\sigma_{lien='Dol'}(S))$$

* car la selection sur la note est un 'filter' traité en Pipeline.

$$\text{coût}(T_1) = \text{card}(\sigma_{lien='Dol'}(S)) \times \frac{F}{\text{card}(S)} = 1$$

→ Diapo 20 page 37.

$$= 2000 \times \frac{1}{100} = 20.$$


$$\text{card}(T_1) = \text{card}(S) \times \frac{1}{100} \times \frac{1}{20} = 1.$$

le 11/03/2022

Suite de l'exo 8 p18

Question 4 b) Plan P2
index sur Stage (nE)

→ les index ne fonctionnent pas sur les résultats Intermédiaires.




on pose $T_1 = \sigma_{\text{mention}='TB'}(\text{Etu})$.

$$\begin{aligned} \text{coût}(P_2) &= \text{coût}(T_1 \bowtie \text{Stage}) = \text{coût}(T_1) + \text{card}(T_1) \times \text{coût}(\sigma_{nE=x}(\text{Stage})) \\ &= \text{coût}(T_1) + \text{card}(T_1) \times \text{card}(\sigma_{nE=x}(\text{Stage})) \longrightarrow (\text{formule J1}). \\ &= \underset{\substack{\uparrow \\ \text{pas d'index} \\ \text{Etu(Mention)}}}{\text{coût}(\text{Etu})} + \text{card}(\text{Etu}) \times \frac{1}{4 \text{ mentions}} \times \text{card}(\text{Stage}) \times \frac{1}{1000 \text{ nb distincts}} \\ &= \text{page}(\text{Etu}) \times c + \dots \\ &= \frac{1000}{10} \times 1 + \frac{1000}{4} \times \frac{2000}{1000} = 100 + 250 \times 2 = 600 \end{aligned}$$


↑ comme ce n'est pas indiqué alors $c=1$.

c) P3 index Stage (lien) + hachage.



→ si non on n'aurait plus le bénéfice de l'index.

→ on obtient donc ceci:



avec: $T_1 = \sigma_{\text{mention}='TB'}(\text{Etu})$
 $T_2 = \sigma_{\text{note} > 19}(\sigma_{\text{lien}='Dol'}(\text{Stage}))$.

$$\begin{aligned}
 \text{coût}(P_3) &= \text{Coût}(T_1) + \text{Coût}(T_2) \longrightarrow \text{formule } T_4 \\
 &= \text{page}(\text{Etu}) \times \underset{\substack{\uparrow \\ =1}}{c} + \text{coût}(\text{Sémin} = 'Dol'(\text{Stage})) \\
 &= \text{page}(\text{Etu}) \times 1 + \text{card}(\text{Sémin} = 'Dol'(\text{Stage})) \\
 &= \text{page}(\text{Etu}) + \text{card}(\text{Stage}) \times \frac{1}{100 \text{ liens distincts}} \\
 &= \frac{1000}{10} + \frac{2000}{100} = 100 + 20 = 120.
 \end{aligned}$$

question 5: Orde des jointures:


Requête avec 4 relations

4! = 24 ordres MAIS certains ordres contiennent un prod cartésien, et ne commencent pas par Stage.

Graphes des jointures :
 node = relation
 arc = prédicat de jointure.

ordres à considérer en partant de S

S P E F
 S E P F
 S E F P



Plan à écarter S F E P

↳ pas de prédicat de jointure entre S et F
 ↳ ya un produit cartésien (car pas d'arc).

Exercice 7 (ref ER1-19-1) : Plan d'une requête

Question 1:

a) Id = 2 access(diplom = 'IT')
 Id = 1 filter(région = 'IDF', université in ('S', 'D'))

b) Pseudo code:

```

for (r: I.formation_diplôme.getRowIds(diplôme = 'IT')):
    t = Formation.lireTuplé(r)
    if (t.region == 'IDF' and t.université in ('S', 'D')):
        affiche(t.nF, t.université)
  
```

correspond au "rang Scan".
 correspond au "Access by Rowid".

Question 2: Utilisation de deux index

$R_1 = I_Etu_Réside.getRowIds("Paris")$


↑ liste de RowIds

$R_2 = I_Etu_NF.getRowIds("F1")$

```
for (r: R1 intersection R2):  
    t = Etudiant.lireTuple(r)  
    if (t.prenom.startsWith('A')):  
        affiche(t.prenom)
```

Question 3: Jointure par branche avec index

on prend les valeurs
qui sont le plus à
gauche ensuite, on
vas sur la plus à
droite.



For (t: Etudiant.tuples()):

↑ table accès FULL.

$r = I_Forma_NF.getRowIds(nF = t.nF)$

↓ new RowID

→ correspond à UNIQUE Scan → donc pas de for.

f = Formation.lireTuple(r)

```
if (f.diplôme = 'h'):  
    affiche(t.prenom, f.region)
```

Question 5: Jointure par hachage

Dictionnaire (contient les données utiles de la branche de gauche)

Une entrée du dict est (nF, liste de prénoms)

clé = attribut de jointure

pseudo code:


initialiser le dictionnaire (table de hachage du hash join)

D = {} par défaut la valeur étant une liste vide

```
for (r: I_Elu_Réside.getRowIds(réside='Aix')):
```

```
    e = Etudiant.getTuple(r)
```

```
    D[e.nF].append(e.prenom)
```



```
for (n: I-farma.Diplome.getRowIDs (diplome='M2')):
```

```
    f: Formation.getTuple(n)
```

```
    for (p: D[f.nF]):
```

```
        affiche (f.université, p)
```