

Architecture des Réseaux (ARes) 4/5 : Réseau

Olivier Fourmaux
olivier.fourmaux@sorbonne-universite.fr

Version 8.4

Couche réseau

La **couche réseau** achemine les paquets de la source vers les destinataires en effectuant des sauts entre les différents **nœuds intermédiaires**

- de bout-en-bout (*end-to-end*)
- connaissance de la topologie
- calcul du chemin (**routage**)
- adressage virtuel
- abstraction des technologies sous-jacentes
 - encapsulation sur chaque technologie
 - adaptation à la taille
 - conversion d'adresses


ARes : plan du cours 4/5

- 1 La couche réseau
 - Rappels
 - Intégration TCP/IP
 - Structure du paquet IPv4/v6
- 2 Adressage et contrôle
 - Adressage IPv4/IPv6
 - Messages de contrôle
 - Mécanismes associés
- 3 Routage
 - Algorithmes de base et hiérarchie de routage
 - Un protocole de routage interne : OSPF
 - Un protocole de routage externe : BGP

ARes : plan du cours 4/5

- 1 La couche réseau
 - Rappels
 - Intégration TCP/IP
 - Structure du paquet IPv4/v6
- 2 Adressage et contrôle
 - Adressage IPv4/IPv6
 - Messages de contrôle
 - Mécanismes associés
- 3 Routage
 - Algorithmes de base et hiérarchie de routage
 - Un protocole de routage interne : OSPF
 - Un protocole de routage externe : BGP


Couche réseaux : OSI



Couche réseau : encapsulation


La couche réseau fait abstraction des technologies sous-jacentes

- les données doivent pouvoir circuler de réseaux en réseaux
- les couches supérieures ne doivent faire aucune hypothèse sur les couches basses



➡ sera approfondie dans le cours sur les **Architectures supports**

Couche réseau : fragmentation




pictures from Tanenbaum A. S. Computer Networks 3rd edition

Couche réseau : adressage


La couche réseau définit un **adressage virtuel** valide sur tous les réseaux

- identification unique d'un équipement
- masquage des mécanismes d'adressages spécifiques à une technologie
- nécessite la mise en correspondance des adresses




➡ sera aussi approfondi dans le cours sur les **Architectures supports**

Couche réseau : modèles de communication



Couche réseau : approche circuit virtuel ou datagramme



pictures from Tanenbaum A. S. *Computer Networks 3rd edition*

Couche réseau : routage

Calcul des chemins

- initial (circuits virtuels)
- à chaque paquet (sans mémoire)

Décisions de routage basées :

- table de routage
 - statique
 - dynamique
 - algorithmes de routage
 - protocoles de routage...

➡ sera approfondi dans la suite du chapitre

ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6


2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage


- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP

Couche Réseaux : TCP/IP



⇒ IPv4/v6 est l'interface universelle

IPv4/v6



Service en mode non connecté à remise non garantie (*best effort*)

ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6

2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage



- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP

IPv4/v6 : structure du packet

v4	IHL	DiffServ	Total Length
	Identification	FF	Fragment Offset
	TTL	Protocol	Header Checksum
	Source Address		
	Destination Address		
	Options (0-10 32 bits lines)		
	Payload (Upper Layer)		



v6	DiffServ	Flow Label	
	Payload Length	Next Hdr	Hop Limit
	Source Address		
	Destination Address		
	Payload (Next Header / Upper Layer)		

IPv4/v6 : versions



- 4 bits
- IP actuels : version 4 et version 6

IPv4 (seulement) : longueur de l'entête





- 4 bits (valeur 15 max)
 - indique le nombre de lignes de 32 bits dans l'entête IP
 - nécessaire car l'entête est de longueur variable (20 à 60 octets)
 - valeur de 5 (pas d'options) à 15 (10 lignes d'options)





la taille de l'entête IPv6 est fixe = 40 octets (10 lignes)

IPv4/v6 : octet pour différencier les services (DiffServ)




- 8 bits pour Diffserv et ECN :
 - 6 bits pour les classes DSCP (DiffServ Code Point)
 - 2 bits pour la notification ECN (*Explicit Congestion Notification*)

IPv6 (seulement) : Identifiant de flot



- 24 bits identifiant une **sequence de paquets** qui doivent être traités de manière spécifique
 - permet une **classification** sans observer les couche supérieures
 - un flot est un **identifiant unique** (du point de vue de la source)
 - les paquets ne sont pas supposés appartenir au même flot après un silence de 120 s
 - actuellement, les **macro-flots** sont préférés aux **micro-flots**
 - indexage dans le réseau (routeurs *ingress* et *egress*)
 - DiffServ dans le réseau d'un fournisseur


IPv4/v6 : taille du paquet



- 16 bits (64 Koctets maximum)
 - taille totale du paquet **avec (IPv4)** ou **sans (IPv6)** l'entête
 - exprimé en octets
 - le réseau support doit accepter un MTU¹ ≥ 576 octets (IPv4) et ≥ 1280 bytes (IPv6)


¹MTU : Maximum Transmission Unit

IPv4 (seulement) : identificateur



- 16 bits (boucle tous les 64 Kpaquets)
- défini de manière **unique** pour chaque paquet
- pour réassembler les fragments d'un **même** paquet
- habituellement, **incrément** d'un compteur pour chaque paquet successif




IPv4 (seulement) : fragmentation



- **Fragmentation non transparente**
 - 1 bit réservé
 - 1 bit DF : *Don't fragment* (=1 interdit la fragmentation)
 - 1 bit MF : *More fragment* (=0 pour le dernier fragment)
 - 13 bits *fragment offset* en bloc de 8 octets (shift 3)
- **exemples** : 0x0000 paquet entier (*offset*=0)
0x2000 premier fragment (*offset*=0)
0x20A0 fragment central (*offset*=1280)
0x00B0 dernier fragment (*offset*=1408)

IPv4 (seulement) : fragmentation

Numero du premier élément du segment contenu dans ce paquet





IPv4/IPv6 : éviter la fragmentation

La fragmentation est coûteuse pour les routeurs :



- évitement avec le **PMTU** (*Path Maximum Transmission Unit*)
 - émission d'un packet non fragmentable
 - chaque routeur qui nécessite une fragmentation retourne un message (*Packet Too Big*)
 - adaptation de l'émetteur (indication à la couche supérieure ou fragmentation initiale)
 - itération jusqu'à l'accessibilité du destinataire
- **IPv4** peut utiliser PMTU avec le bit DF positionné à 1
- **IPv6** utilise **systématiquement** le PMTU
 - fragmentation initiale possible via une extension de l'entête

IPv4/v6 : Temps de vie / Limite des sauts



- 8 bits
- unité initiale du TTL IPv4 : **seconde**
- valeur maximum fixé par l'émetteur (255, 128, 64...)
- décrément dans chaque routeur
 - minimum 1 par routeur ➡ nombre de **sauts**
- max 255 sauts
- **évite les boucles**

IPv4/v6 : protocole transporté/encapsulé



- 8 bits
- mux/démux vers les proto. de la couche sup. (ou entête IPv6) :



```

Unix> cat /etc/protocols
ip 0 # pseudo protocol number
icmp 1 # internet control message protocol
igmp 2 # internet group management protocol
ipencap 4 # IP encapsulated in IP
tcp 6 # transmission control protocol
udp 17 # user datagram protocol
iso-tp4 29 # ISO Transport Protocol class 4
dccp 33 # Datagram Congestion Control Proto.
xtp 36 # Xpress transport protocol
ipv6 41 # ipv6 encap
    
```

```

ipv6-route 43 # routing header for ipv6
ipv6-frag 44 # fragment header for ipv6
rsvp 46 # Reservation Protocol
gre 47 # General Routing Encapsulation
esp 50 # encapsulating security payload
ah 51 # authentication header
ipv6-icmp 58 # ICMP for IPv6
ipv6-nonxt 59 # no next header for ipv6
ipv6-opts 60 # destination options for ipv6
ospf 89 # Open Shortest Path First
sctp 132 # Stream Control Transmission
    
```



IPv4 (seulement) : contrôle d'erreur sur l'entête



- 16 bits
- idem UDP/TCP mais que sur l'entête
- émetteur :
 - $checksum^2 = \sum mot_{16bits}$
- récepteur : recalcul de la somme
 - = 0 : pas d'erreur détectée toujours possible...
 - ≠ 0 : erreur (destruction silencieuse)



²Somme binaire sur 16 bits avec report de la retenue débordante

IPv4/v6 : adresses source et destination





- 32 bits (IPv4) or 128 bits (IPv6)
- identifie l'émetteur ou le récepteur du paquet
- l'adresse destination est utilisée pour le routage
- l'adresse source permet de retourner un message à l'émetteur (ICMP, UDP...)

IPv4/v6 : extension d'entête



- IPv4 : entête extensible via le champ de longueur variable
- IPv6 : encapsulation successive d'entêtes

IPv4 : options




- 0 à 40 octets (alignés sur 32 bits)
- système TLV identique à TCP
- exemples :
 - enregistrement de la route
 - routage à la source strict ou relâché
 - estampilles temporelles, sécurité...
- analysées dans chaque routeur ➡ A éviter!


IPv6 : extension d'entête

Chainage d'entêtes supplémentaires :


- similaire à un protocole de niveau supérieur
- pas de limitation de taille
- traitement à la destination (sauf hop-by-hop) ➡ label
- ordre important...
- difficulté d'accès au numéro de ports (pare-feux)
- peu utilisées en pratique



IPv6 : extension d'entête



IPv6 : extension d'entête



ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6

2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage

- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP

Adressage : principe

Routage basé sur l'adresse destination facilement accessible :

- position fixe dans l'entête
- taille fixe
- alignement mémoire

Adresse IPv4 (1981)

- 32 bits (4 octets)

Adresse IPv6 (1996)

- 128 bits (16 octets)

Adressage : notations standardisées

Adresse IPv4

- notation **décimale pointée**
 - écriture en **décimal** chacun des 4 octets séparés par des points
 - exemple : `132.77.12.2`


Adresse IPv6

- format de base :
 - écriture en **hexadécimale** de chacun des mots de 16 bits séparés par `:`
 - exemple : `2001:0db8:abcd:0001:0000:0000:1234:5678`
- format compact :
 - retirer les 0 à gauche de chaque blocs de 16 bits
 - substituer **seulement** une séquence de zéros par `::`
 - exemple : `2001:db8:abcd:1::1234:5678`
- intégration d'une adresse IPv4 :
 - exemple : `::ffff:192.1.2.3`

Adressage : hostId/netId

Adresses composée de 2 parties

identifiants du réseau (netId) et de l'hôte (hostId) sont associés dans les adresses IPv4 et IPv6, exemple (IPv4) :



Adressage : préfixe/masque

Indication de la taille de l'identifiant de réseau (netId) :

- notation par **préfixe** : `132.77.0.0/16`
- notation par **masque** : `132.77.0.0 netmask 255.255.0.0`

Application de masques binaires

- extraction du netId (exemple IPv4)

132.227. 60.135	netId.hostId
&& 255.255. 0. 0	&& netmask
132.227. 0. 0	netId. 0. 0

- extraction du hostId (exemple IPv4)

132.227. 60.135	netId.hostId
&& 0. 0.255.255	&& !netmask
60.135	hostId

IPv4 : adressage avec classes

32 Bits			
			Range of host addresses
Class			
A	0	Network	Host
			1.0.0.0 to 127.255.255.255
B	10	Network	Host
			128.0.0.0 to 191.255.255.255
C	110	Network	Host
			192.0.0.0 to 223.255.255.255
D	1110	Multicast address	
			224.0.0.0 to 239.255.255.255
E	11110	Reserved for future use	
			240.0.0.0 to 247.255.255.255

pictures from Tanenbaum A. S. *Computer Networks 3rd edition*

Adressage IPv4 : masques + spécifique

Utilisation des masques binaires

classe	masque binaire	netmask	prefixe
A	11111111000000000000000000000000	255.0.0.0	/8
B	11111111111111000000000000000000	255.255.0.0	/16
C	1111111111111111111100000000	255.255.255.0	/24

Adresses particulières

- pour chaque réseau (netId), 2 adresses de réservées :
 - netId.000...000 ➡ identification de ce réseau
 - netId.111...111 ➡ adresse de diffusion de ce réseau
- autres :
 - 000...000 ➡ adresse source inconnue
 - 111...111 ➡ adresse de diffusion locale
 - 127.x.y.z ➡ adresse de rebouclage logiciel (*loopback*)

Adressage : subnetting (1)


Taille de l'identifiant de réseau (netId) initiale :

- 132.77.0.0 /16 (notation par **préfixe**)
- 132.77.0.0 netmask 255.255.0.0 (notation par **masque**)


Subdivision possible :

- 132.77.12.0 /22
- 132.77.12.0 netmask 255.255.252.0


Adressage : subnetting (2)




Adressage : subnetting (3)



Adressage : affectation




Processus de routage



Destination	Gateway	Genmask	Flags	Metric	Ref	Use	Iface
192.33.182.0	0.0.0.0	255.255.255.0	U	0	0	0	eth0
10.0.0.0	0.0.0.0	255.0.0.0	U	0	0	0	atm0
154.18.2.0	0.0.0.0	255.255.255.0	U	0	0	0	eth1
132.77.0.0	154.18.2.254	255.255.0.0	UG	0	0	0	eth1
default	192.33.182.254	0.0.0.0	UG	0	0	0	eth0

Routage : *longest prefix match*



Destination	Gateway	Genmask	Flags	Metric	Ref	Use	Iface
20.0.0.0	0.0.0.0	255.0.0.0	U	0	0	0	if1
30.0.0.0	0.0.0.0	255.0.0.0	U	0	0	0	if2
50.0.0.0	0.0.0.0	255.0.0.0	U	0	0	0	if3
50.2.0.0	20.1.2.3	255.255.0.0	UG	0	0	0	if1
50.1.2.3	20.1.0.1	255.255.255.255	UGH	0	0	0	if1
60.126.6.0	40.0.0.1	255.255.255.0	UG	0	0	0	if2
default	30.0.0.1	0.0.0.0	UG	0	0	0	if2

IPv4 : adressage sans classe (CIDR)

L'attribution des adresses IP avec classe est **inefficace**

- adresses allouées par blocs de 256, 65K ou 16M
- les sous-réseaux permettent une meilleure gestion

CIDR (*Classless InterDomain Routing*)

- un adressage **sans classe** augmente la souplesse dans l'attribution des adresses :
 - permet d'utiliser toute les adresses d'un bloc d'adresses contiguës à **préfixe identique**
 - permet aux routeurs de maintenir une seule entrée de table de routage
 - utilisé pour toutes tailles de bloc d'adresses possible dans tout l'espace d'adressage des ex-classes A, B et C
 - exemple : 81.152.12.0/22

Adressage : Calcul CIDR


Un bloc CIDR est donc l'agrégation d'un ensemble d'adresses

- **bits réseau** (netId) d'un bloc CIDR correspondent aux N bits les plus à gauche ($/N$ définit le masque réseau du bloc CIDR)
- **bits hôte** (hostId) du bloc CIDR correspondent aux $32 - N$ bits restants
- ensemble des adresses attribuables dans un bloc CIDR :
 - premier hôte : hostId = 000...0001
 - dernier hôte : hostId = 111...1110
 - adresse de diffusion : hostId = 111...1111
 - exemple :

Bloc CIDR -> 192.77.20.0/22
 @ premier hôte : 192.77.20.1
 ...
 @ dernier hôte : 192.77.23.254
 @ de diffusion : 192.77.23.255

Adressage : découpage des blocs CIDR

Les blocs d'adresses CIDR se divisent en sous-bloc selon le principe du découpage en sous-réseau (*subnetting*)



IPv4 : Adresses publiques ou privées

Adressage public


tout hôte connecté à l'Internet doit avoir une adresse unique valide

Adressage privé

pour un usage de TCP/IP déconnecté de l'Internet

- gestion autonome d'un plan d'adressage (adresses uniques)
- utilisation de plages d'adresses spécifiques **recommandée** :
 - **adresses non routées** (adresses privées) :
 - 10.0.0.0/8 (1 ex-classe A)
 - 172.16.0.0/12 (16 ex-classe B)
 - 192.168.0.0/16 (256 ex-classes C)
 - 169.254.0.0/16 (*link local block* pour l'auto-configuration)
 - utilisable dans chaque *internet* privé
 - même en cas de connexion à l'Internet, trafic non relayé
 - communication vers l'Internet possible (proxy, NAT...)

IPv4 : NAT (*Network Address Translation*)



pictures from Tanenbaum A. S. *Computer Networks 4rd edition*

IPv4 : NAT, DNAT et NAPT

Plusieurs approches de la conversion d'adresses :

NAT statique : correspondance fixe d'adresses

NAT dynamique : correspondance dynamique d'adresses

☞ table d'adresses dynamique :

adresse privée	adresse publique
10.0.0.3	192.33.182.117
10.0.0.4	192.33.182.118
...	...

NAPT (CISCO NAT overload) : correspondance dynamique vers une adresse (ou plusieurs adresses) avec surcharge

☞ ports + table dynamique (pour chaque protocole) :

proto	adr. privée	port privée	adr. publique	port public
TCP	10.0.0.3	1027	192.33.182.117	1027
TCP	10.0.0.4	1027	192.33.182.117	1028
UDP	10.0.0.4	31765	192.33.182.117	31765
...	...	...	...	...

IPv4 : mécanismes NAPT

Où sont modifiées les adresses ?

☞ au niveau de la carte d'interface :

NAT en entrée ➡ processus de routage ➡ NAT en sortie


Modifications annexes :

- le *checksum* des entêtes doit être recalculé
 - NAT** IP, TCP et UDP (adresse + *pseudo-header*)
 - NAPT** IP, TCP et UDP (adresse + *pseudo-header* + port)
- les adresses et ports paramètres de protocoles applicatifs doivent être aussi modifiés (commande PORT de FTP)
- les messages ICMP sont analysés


IPv4 : NAT et IETF (RFC 1631)

- NAPT très fortement utilisé** actuellement
 - entreprises (flexibilité)
 - fournisseurs de services (manque d'adresses)
 - particuliers (n'ont qu'une adresse)
- pose qqs **problèmes**
 - architecturaux :
 - les ports doivent identifier des processus et non des machines
 - modification de paramètres de la couche transport par le réseau
 - principe de bout-en-bout** : 2 hôtes doivent communiquer directement
 - sécuritaires : incompatible avec les mécanismes d'**authentification**
 - techniques : comment "entrer" dans le réseau translaté
- solutions**
 - court terme ➡ conversions statiques, serveurs intermédiaires
 - long terme ➡ IPv6

IPv4 : adresses multicast



IPv4 : adressage multicast



Les communications IP multicast (RFC 1112) reposent sur :

- une abstraction de groupe (adresse virtuelle de la classe D)
- une adhésion au groupe initiée par les récepteurs (voir IGMP)
- une transmission vers les destinataires du groupe gérée par les routeurs

IPv4 : adresses multicast réservées

224.0.0.0	Base address (reserved)
224.0.0.1	All Hosts multicast group (all hosts on the same link)
224.0.0.2	All Routers multicast group (all routers on the same link)
224.0.0.4	All DVMRP Routers
224.0.0.5	All OSPF Routers (for Hello to all OSPF routers on a link)
224.0.0.6	All OSPF Designated Routers (for routing information to DR on a link)
224.0.0.9	All RIP2-aware Routers (information to all RIP2 routers on a link)
224.0.0.10	All EIGRP Routers
224.0.0.13	Protocol Independent Multicast v2 (PIMv2)
224.0.0.18	Virtual Router Redundancy Protocol (VRRP)
224.0.0.19-21	IS-IS over IP
224.0.0.22	Internet Group Management Protocol v3 (IGMPv3)
224.0.0.102	Hot Standby Router Protocol v2 (HSRPv2)
224.0.0.107	Precision Time Protocol v2 peer delay measurement
224.0.0.251	Multicast DNS (mDNS) address (for ZeroConf)
224.0.0.252	Link-local Multicast Name Resolution (LLMNR) address
224.0.0.253	Teredo tunneling client discovery address
224.0.1.1	NTP clients listen on this when operating in multicast mode

IPv6 : adresses sur 128 bits

Pourquoi des adresses de taille beaucoup plus grandes ?

- IPv4 : 6 adresses par habitant aux USA, 1 en Europe, 0.01 en Chine et 0.001 en Inde
- IPv6 : 50 milliards de milliards de milliards d'adresses par habitants sur terre

Des adresses pour tout **dans le réseau** (et pas pour tout)

- dépend de la position dans le réseau
- pas d'adresses permanentes (*renumbering, deprecation...*)

Allocation d'adresses IPv6 (RFC 4291) :

- les interfaces réseau ont plusieurs adresses IPv6 :
 - adresse locale (*link local*), adresse globale...
- utilise les principes de CIDR avec la notation prefix :
2001:db8:1234::/48
- rebouclage logiciel (*loopback*) ::1

IPv6 : espace d'adressage

0000::/8	Reserved by IETF [RFC4291]
0100::/8	Reserved by IETF [RFC4291]
0200::/7	Reserved by IETF [RFC4048]
0400::/6	Reserved by IETF [RFC4291]
0800::/5	Reserved by IETF [RFC4291]
1000::/4	Reserved by IETF [RFC4291]
2000::/3	Global Unicast [RFC4291]
4000::/3	Reserved by IETF [RFC4291]
...	
c000::/3	Reserved by IETF [RFC4291]
e000::/4	Reserved by IETF [RFC4291]
f000::/5	Reserved by IETF [RFC4291]
F800::/6	Reserved by IETF [RFC4291]
fc00::/7	Unique Local Unicast [RFC4193]
fe00::/9	Reserved by IETF [RFC4291]
fe80::/10	Link Local Unicast [RFC4291]
fec0::/10	Reserved by IETF [RFC3879]
ff00::/8	Multicast [RFC4291]

IPv6 : types d'adresses

Plusieurs types d'adresses sont définies avec IPv6 :

- la plage réservée de préfixe 0::/8 est utilisée pour les adresses spéciales (indéterminées, de rebouclage, de correspondance, compatible IPv4...)
- Global Unicast** : adresses point-a-point équivalentes aux adresses publiques d'IPv4
- Unique Local Unicast** : similaire aux adresses privées d'IPv4
- Link-Local** : adresses utilisables vers les hôtes accessibles directement (non routable)
- Multicast** : similaire aux classes D d'IPv4

IPv6 : Local Link Address

10	54	64
FE80	0000:0000:0000	Interface ID

Adresses avec une validité restreinte au lien :

- non routable
- configurées automatiquement à l'initialisation de l'interface
- utilisée principalement pour l'auto-configuration
- communication directe d'hôtes connectés au même lien
- même préfixe sur tts les interfaces fe80::/10** : ajout %iface
- Interface ID** est un identifiant :
 - dérivée d'un identifiant de la couche 2 (i.e. adresse MAC)
 - pas de problème d'anonymat
 - MAC-48** ➔ **EUI-64** en rajoutant 0xFFFE entre les 3 octets de début (*Vendor*) et les 3 de fin (*Serial*)
 - EUI-64** ➔ **Interface ID** en inversant le 2^{me} bit du 1^{er} octet

IPv6 : Global Unicast Address

3	45	16	64
(001) ₂	Global Prefix	SID	Interface ID

Adresses avec une portée globale similaires aux adresses IPv4 publiques

- Global prefix** est fixée par le fournisseur de service (topologie publique)
- SID** est fixée localement (topologie locale)
 - peut être réduit pour les réseaux résidentiels (/56 ou /60)
- Interface ID** est un identifiant qui peut être soit :
 - dérivée d'un identifiant de la couche 2 (i.e. adresse MAC)
 - problème d'anonymat
 - attribuée manuellement (même adresse quand changement de carte réseau)
 - une valeur aléatoire changeante (pour garantir l'anonymat)

IPv6 : Unique Local Unicast Address

8	40	16	64
FD	Random Value	SID	Interface ID

Adresses non routable similaires aux adresses IPv4 privées

- Random Value** globalement unique (topologie privée)
 - préfixe identifiée pour le filtrage
 - indépendant du fournisseur d'accès
 - interconnexion de site sans conflits
- SID** est allouée localement (topologie locale)
- Interface ID**

IPv6 : Multicast Address

8	4	4	112
FF	xRTP	Scope	Groupe ID

Adresses similaires aux adresses IPv4 multicast

- **R** (*Transient*) 0 : adresses connues / 1 : adresses temporaires
- **P** (*Prefix*) 1 : assignées à partir du préfixe réseau
- **T** (*Rendez Vous Point*) 1 : contiens l'adresse du RP
- **Scope**
 - 1 - interface-local
 - 2 - link-local
 - 4 - admin-local
 - 5 - site-local
 - 8 - organisation-local
 - e - global

IPv6 : Multicast Address

8	4	4	112
FF	xRTP	Scope	Groupe ID

Adresses connues :

ff02::1 All Nodes Address (link-local scope)
 ff02::2 All Routers Address
 ff02::5 OSPFIGP
 ff02::6 OSPFIGP Designated Routers
 ff02::9 RIP Routers
 ff02::fb mDNSv6
 ff02::1:2 All-dhcp-agents
 ff02::1:ffxx:xxxx Solicited-Node Address
 ff05::1:3 All-dhcp-servers (site-local scope)

ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6

2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage

- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP


IPv4 : ICMP (*Internet Control Message Protocol*, RFC 792)

Encapsulé dans un paquet IP (mais appartient à la couche 3)

➡ test et diagnostique du réseau

ICMP Type	Code	Description
0	0	↔echo reply
3	0	destination network unreachable
3	1	destination host unreachable
3	2	destination protocol unreachable
3	3	destination port unreachable
3	6	destination network unknown
3	7	destination host unknown
4	0	source quench
8	0	→echo request
9	0	router advertisement
10	0	router discovery
11	0	TTL expired
11	1	reassembly time exeeded
12	0	IP header bad

ICMP : echo




Type	Code	Checksum	Identifiant	Seq. Num.	Data
8 (Echo Request)	0				
0 (Echo Response)	0				
1 octet	1	2	2	2	...

Teste l'accessibilité d'un équipement

- utilisé par la commande ping :
 - indique la connectivité et la disponibilité d'IP chez le destinataire
 - plusieurs messages permettent d'estimer le RTT et le taux de perte

ICMP : destination inaccessible




Type	Code	Checksum	Unused	Data
3	0 (Net Unreachable) 1 (Host Unreachable) 2 (Protocol Unreachable) 3 (Port Unreachable)			IP Header + 64 bits
1 octet	1	4	2	(IHL * 4) + 8

Message sent when the destination cannot be reached

- the IP header and some transport layer information are returned
 - @ source = originator of the ICMP message
 - @ destination = @ source of the packet in question

ICMP : expiration de temporisation



Type	Code	Checksum	Unused	Data
11	0 (Time To Live Exceeded) 1 (Frag. Reass. Time Exceeded)			IP Header + 64 bits
1 octet	1	4	2	(IHL * 4) + 8

Messages émis lorsque le temps de vie ou de réassemblage est dépassé.

- l'entête IP et une partie de la couche transport sont retournés
 - @ source = créateur du message ICMP
 - @ destination = @ source de l'émetteur du paquet en cause
- utilisé par la commande traceroute

ICMP : autres messages

- Source Quench (Type 4)**
 - indique une congestion à la source
 - pas de signalisation de fin de congestion
- Redirection (Type 5)**
 - indique si une meilleure route est disponible
 - configuration minimale des hôtes
- autres messages principalement pour l'autoconfiguration

IGMP

Internet Group Management Protocol

Protocole qui permet aux routeurs de gérer la composition des groupes multicast :

- **IGMPv1** (RFC 1112) : 2 messages
 - requête d'adhésion (*membership query*) vers 224.0.0.1
 - émis par le routeur vers tous les hôtes multicast
 - rapport d'adhésion (*membership report*) vers le groupe concerné
 - émis après temporisation par les membres du groupe
- **IGMPv2** (RFC 2236) : ajout de 2 messages
 - requête spécifique (*membership query*) vers un groupe
 - permet de vérifier s'il y a des membres (après des départs)
 - message pour quitter (*leave*) vers le groupe concerné
- **IGMPv3** (RFC 3376) :
 - optimisation pour le multicast avec indication de la source

ICMPv6

ICMPv6 (RFC 4443) est différent d'ICMP + IGMP pour IPv4

- numéro de protocol : 58
- fonctionnalités étendues et mieux organisées :
 - Error occurs during forwarding** (value < 128)

1 Destination Unreachable	3 Time Exceeded
2 Packet Too Big	4 Parameter Problem
 - Management applications** (value > 128)

128 Echo Request	133 Router Solicitation
129 Echo Reply	134 Router Advertisement
130 Group Membership Query	135 Neighbor Solicitation
131 Group Membership Report	136 Neighbor Advertisement
132 Group Membership Reduction	137 Redirect
- **ne jamais filtrer des messages ICMPv6** (RFC 4890)
- contrôle d'erreur obligatoire

ARes : plan du cours 4/5

- 1 La couche réseau
 - Rappels
 - Intégration TCP/IP
 - Structure du paquet IPv4/v6
- 2 Adressage et contrôle
 - Adressage IPv4/IPv6
 - Messages de contrôle
 - Mécanismes associés
- 3 Routage
 - Algorithmes de base et hiérarchie de routage
 - Un protocole de routage interne : OSPF
 - Un protocole de routage externe : BGP

IPv4 : RARP (Reverse Address Resol. Protocol, RFC 903)

Inverse du protocole ARP (réseaux à diffusion)

- obtention d'une @ IP à partir de @ MAC au démarrage
 - hôtes sans disques (terminaux X, imprimantes...)
 - hôtes mobiles (portable changé de réseau...)
- utilisation d'un **serveur** (rarpd)
 - mise en correspondance de /etc/ethers et de /etc/hosts
- format des trames identique à ARP
 - type Ethernet : 0x8035
 - code 3 pour une requête RARP
 - code 4 pour une réponse RARP
- exemple d'autoconfiguration :
 - la nouvelle station déclenche un échange **RARP**
 - la station demande le *netmask* par un échange **ICMP**
 - la station demande au serveur RARP son programme de démarrage par *tftp*

IPv4 : BOOTP (*BOOT Protocol*, RFC 951 et 1542)

- protocole **portable**, sur UDP
 - requête sur le port **68** (serveur), réponse sur le port **67** (client)
 - quelles *addresses IP* utiliser lorsqu'on n'en connaît aucunes ?
 - @ IP de diffusion (255.255.255.255)
 - @ IP par défaut (0.0.0.0)
 - permet d'atteindre un serveur sur un autre réseau
 - à travers des agents BOOTP relais
 - nombreuses extensions (RFC 1533)
 - netmask*
 - liste des **routeurs** du sous-réseau
 - liste de **serveurs NTP**
 - liste des **serveurs de noms** (DNS)
 - liste des serveurs d'impression (LPD et autres)
 - hostname* et *domainname*
 - TTL par défaut ...


IPv4 : DHCP (*Dynamic Host Config. Protocol*, RFC 2131)

Extension compatible de BOOTP avec gestion dynamique des @IP

- attribution dynamique par **bail** (*lease*) limité dans le temps
 - bail renouvelé périodiquement si nécessaire
- nouvelles **options DHCP** (extensions BOOTP) :

DHCPDISCOVER	C → S	localisation du serveur
DHCPOFFER	S → C	proposition au client
DHCPREQUEST	C → S	confirmation d'une proposition
DHCPACK	S → C	validation d'une configuration
DHCPNACK	S → C	invalidation d'une configuration
DHCPDECLINE	C → S	refus d'une configuration invalide
DHCPRELEASE	C → S	libération d'une configuration
DHCPINFORM	C → S	demande d'information autre que @ IP
DHCPFORCERENEW	S → C	demande de reconfiguration

IPv4 : échanges DHCP



ND : Auto-configuration IPv6 sans états

Les nœuds IPv6 partageant le même support physique (*link*) utilisent **Neighbor Discovery** (ND) pour :


- determine l'adresse lien de ses voisins
 - IPv4 : ARP
- auto-configuration d'adresse
 - parametres de la couche 3 : adresse IPv6, route par default, MTU et limite de saut
 - seulement pour les machines terminales
 - IPv4 : impossible, délègue à un serveur DHCP
- Duplicate Address Detection (DAD)
 - IPv4 : gratuitous ARP
- maintien l'information d'accès aux voisins (NUD)
- remarques
 - utilise principalement des adresses multicast
 - paquets du protocole sont transportée/encapsulée dans des paquets ICMPv6

DHCPv6 : Auto-configuration IPv6 avec et sans état

Similaire au DHCP classique avec :

- le routeur du lien peut indiquer l'utilisation d'un serveur DHCPv6 lors d'une réponse à un RS
- requête sur le port **547** (serveur), réponse sur le port **546** (client)
- adresse source locale au lien : `fe80::<IID>`
- adresse destination multicast connue : `ff02::1:2` (tous les serveurs DHCP du lien local)
- si besoin, relaiage vers les serveurs DHCPv6 du site


Tunneling



- encapsulation** alternative à la traduction (*translation*)
- traversées de zones avec des protocoles différents
 - ex : relier des îlots avec des protocoles non généralisés (IPmulticast, IPv6...)
- contrôle du flux de T1 à T2 (IPv4 dans IPv4, VPN...)
- VPN...

VPN (Virtual Private Network)


- layer 3 VPN : integrates security and automation
 - IPSEC : confidentiality and integrity (RFC 4301 à 4309)
 - AAA (*Authentication, Autorisation, Accounting*)
- other VPN approaches at layer 2 (PPP...)



pictures from Tanenbaum A. S. Computer Networks 4rd edition

Filtrage d'adresses

Firewall...



pictures from Tanenbaum A. S. Computer Networks 3rd edition

ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6

2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage


- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP

Synthèse sur la couche réseau

La **Couche Réseau** achemine les paquets de la source vers les destinataires en effectuant des sauts entre les différents **nœuds intermédiaires**

- acheminement de bout-en-bout (*end-to-end*)
 - adressage virtuel
- connaissance locale de la topologie
 - besoin d'informations pour orienter les PDU
 - statique : configuration manuelle
 - dynamique : algorithmes et protocoles de routage
- adaptation à la taille du réseau
 - structure hiérarchique (AS)
 - routage interne : RIP, EIGRP, OSPF, IS-IS
 - routage externe : BGP-4

Routage



Routage dans l'hôte : GNU/Linux

```

Unix> /sbin/ifconfig eth0
eth0 Link encap:Ethernet HWaddr 00:20:ED:87:FD:E6
      inet addr:132.227.61.122 Bcast:132.227.61.255 Mask:255.255.255.0
      UP BROADCAST NOTRAILERS RUNNING MULTICAST MTU:1500 Metric:1
      RX packets:1115393 errors:0 dropped:0 overruns:0 frame:0
      TX packets:966470 errors:0 dropped:0 overruns:0 carrier:0
      collisions:0 txqueuelen:100
      RX bytes:445681702 (425.0 Mb) TX bytes:370060277 (352.9 Mb)
      Interrupt:9 Base address:0x6f00
    
```

```

Unix> /sbin/route
Kernel IP routing table

```


Destination	Gateway	Genmask	Flags	Metric	Ref	Use	Iface
132.227.61.0	*	255.255.255.0	U	0	0	0	eth0
127.0.0.0	*	255.0.0.0	U	0	0	0	lo
default	132.227.61.200	0.0.0.0	UG	0	0	0	eth0

Routeur dans l'hôte : MS Windows

```
C:\Program Files\Support Tools>ipconfig
Ethernet carte Connexion au réseau local :
    Suffixe DNS spéc. à la connexion. :
    Adresse IP. . . . . : 132.227.61.136
    Masque de sous-réseau . . . . . : 255.255.255.0
    Passerelle par défaut . . . . . : 132.227.61.200
```

```
C:\Program Files\Support Tools>route print
=====
Liste d'Interfaces
Ox1 ..... MS TCP Loopback interface
Ox1000003 ...00 03 47 7c b9 d5 ..... Intel(R) PRO Adapter
=====
Itinéraires actifs :
    Destination réseau    Masque réseau    ADR. passerelle    ADR. interface    Métr.
    0.0.0.0                0.0.0.0          132.227.61.200     132.227.61.136    1
    127.0.0.0              255.0.0.0        127.0.0.1          127.0.0.1         1
    132.227.61.0           255.255.255.0    132.227.61.136     132.227.61.136    1
    132.227.61.136         255.255.255.255  127.0.0.1          127.0.0.1         1
    132.227.61.255         255.255.255.255  132.227.61.136     132.227.61.136    1
    224.0.0.0              224.0.0.0        132.227.61.136     132.227.61.136    1
    255.255.255.255        255.255.255.255  132.227.61.136     132.227.61.136    1
    Passerelle par défaut : 132.227.61.200
=====
```


Types de routage



Configuration du routeur :

- statique
- dynamique (en particulier lorsqu'il y a des liens redondants)
 - protocoles et algorithmes de routage
 - ordinateurs : Unix avec logiciels routed, gated, GNU Zebra, Quagga...
 - matériels dédiés : Cisco, Juniper, Alcatel, Hp...

Routeur



Routeur et "relayage" (*forwarding*)

- interfaces (terminaisons physiques, encapsulation...)
- files d'attente
- système de **relayage** (mémoire partagée, bus ou *crossbar*)
- système de **routage**
 - table, algorithmes et protocoles de routage

ARes : plan du cours 4/5


- 1 La couche réseau
 - Rappels
 - Intégration TCP/IP
 - Structure du paquet IPv4/v6
- 2 Adressage et contrôle
 - Adressage IPv4/IPv6
 - Messages de contrôle
 - Mécanismes associés
- 3 Routage
 - Algorithmes de base et hiérarchie de routage
 - Un protocole de routage interne : OSPF
 - Un protocole de routage externe : BGP

Algorithmes de routage

Optimisation d'un critère

- plus court chemin
 - vecteurs de distance
 - état des liaisons
- routage politique
 - vecteurs de chemin
- routage multipoint
 - plus court chemin
 - coût minimum (arbre de steiner)
 - arbres centrés
 - voir le module ROUT

Principe du routage à vecteur de distance



Les routeurs ne connaissent initialement que leurs propres liaisons. Ils diffusent leurs vecteurs de distance (table de routage sans les interface) à leur voisins

➡ Algorithme de Bellman-Ford distribué (ou Ford-Fulkerson 1962)

A la réception d'un vecteur, un routeur intègre l'information dans sa table :

- rajout des entrées nouvelles en indiquant l'interface d'arrivée
- modifier le coût des entrées
 - si un plus court chemin est proposé
 - si un plus long chemin est proposé par l'interface déjà choisie

➡ les échanges successifs doivent amener à la **convergence**

Routage par vecteurs de distance


Algorithme simple basé sur :

- l'échange d'informations entre routeurs adjacents (liaison directe)
 - vecteur de distance ($\neq$ table de routage)
- propagation de proche en proche de l'accessibilité du réseau

... mais limité à des réseaux de taille réduite

- utilisé sur des sites avec quelques routeurs pour éviter les configurations manuelles
- problème avec les informations de seconde main

Exemple de table issue des vecteurs de distance



(a)

					New estimated delay from J	
To	A	I	H	K	Line	
A	0	24	20	21	8	A
B	12	36	31	28	20	A
C	25	18	19	36	28	I
D	40	27	8	24	20	H
E	14	7	30	22	17	I
F	23	20	19	40	30	I
G	18	31	6	31	18	H
H	17	20	0	19	12	H
I	21	0	14	22	10	I
J	9	11	7	10	0	—
K	24	22	22	0	6	K
L	29	33	9	9	15	K
JA delay is 8					New routing table for J	
JI delay is 10						
JH delay is 12						
JK delay is 6						
Vectors received from J's four neighbors						
(b)						


Vectors received from J's four neighbors

(b)

Limitations du routage à vecteur de distance

Plusieurs problèmes sont apparus avec ces algorithmes :

- convergence lente
- risques de boucle
 - horizon partagé (*split horizon*)



- envoi de vecteurs avec tous les réseaux de la table de routage
 - taille de réseau limitée

Routage par état des liaisons (*Link State*)



Comment s'adapter à des réseaux importants tout en évitant la propagation des informations de proche en proche ?

- **connaître son voisinage**
- construire une synthèse de l'info locale
- **diffuser l'info locale** à tous les routeurs
- construire un **graphe** représentant le réseau
- calculer le **plus court chemin** (SPF) vers tous les routeurs

Etat des liaisons : Acquisition du voisinage


But : création d'un graphe équivalent

- envoi de paquets de détection sur les liaisons
- supports partagés (LAN) remplacés par un seul nœud virtuel



Pour pondérer les liaisons, possibilité de réaliser des mesures

Etat des liaisons : Construction des paquets de contrôle



(b)

Link		State		Packets	
A	B	C	D	E	F
Seq.	Seq.	Seq.	Seq.	Seq.	Seq.
Age	Age	Age	Age	Age	Age
B 4	A 4	B 2	C 3	A 5	B 6
E 5	C 2	D 3	F 7	C 1	D 7
	F 6	E 1		F 8	E 8

pictures from Tanenbaum A. S. *Computer Networks 3rd edition*

Etat des liaisons : Distribution des paquets de contrôle

Les routeurs doivent recevoir les messages de **tous les routeurs** :


- besoin d'une distribution fiable
 - numéro de séquence
 - âge de la connexion
- diffusion de routeur en routeur sans modification du contenu des messages

Problème de **consistance** pendant la diffusion de changements

⇒ **Système hiérarchique** à envisager pour les gros réseaux.


Etat des liaisons : Calcul des routes

Algorithme du plus court chemin de **Dijkstra** :




pictures from Tanenbaum A. S. *Computer Networks 3rd edition*

Organisation de très grand réseaux : Internet




AS (Autonomous System, RFC 1930)



Un AS est un ensemble d'un ou plusieurs préfixes IP interconnectés et gérés par un ou plusieurs opérateurs de réseaux qui fonctionnent avec une **unique politique de routage clairement définie**.


AS : organisation externe (1)

Les relations entre AS sont basées sur la notion de **client/fournisseur**



AS : routage simple

Pour un réseau d'extrémité (*stub network*) :




➡ Annonce directe :

- ses préfixes sont annoncés pour qu'il reçoive son trafic entrant
- le réseau d'extrémité envoie tout son trafic sortant vers le reste de l'Internet

AS : organisation externe (2)

Relation économique :




- les fournisseurs font payer leurs clients
 - les pairs échangent gratuitement du trafic
 - les contrats sont confidentiels!
- Tier-1 : les plus gros fournisseurs
 - en 2019 : **AT&T** (ex-Worldnet), **CenturyLink** (ex-Qwest & Savvis (ex-MCI)), **Deutsche Telekom Global Carrier** (DE), **GTT Communications** (ex-Tinet (ex-Tiscali)), **KPN** (NL), **Liberty Global** (UK), **NTT International** (JP, ex-Verio), **Orange** (FR, ex-OpenTransit), **PCCW Global**, **Sprint** (JP, Softbank, Tata (IN, ex-Teleglobe), **Telecom Italia Sparkle**, (IT, ex-Seabone), **Telxius**, (SP, Telefonica), **Telia Carrier** (SE), **Verizon** (ex-UUnet+XO Comm.), **Zayo Group** (ex-Level 3 & Global Crossing)

- a network that can reach every other network on the internet without purchasing IP transit or paying settlements
- infrastructure mondiale et possèdent leur propre réseau

AS : routage entre multiples AS


Pour les réseaux d'infrastructure (*transit network*) :



➡ Comment trouver son chemin à travers plusieurs possibilités ?

AS : critère optimal du routage

Routage politique (critère commercial) :




➡ Ce n'est pas forcément le plus court chemin !

AS : routage politique

Intégration des contraintes politiques :

- nouvelles règles ;
 - un AS accepte le trafic de ou vers ses clients
 - un AS n'accepte pas le trafic de transit entre deux clients de ses concurrents
 - besoin d'un nouveau type de routage !
- but simple :
 - un FAI route le trafic en provenance d'un des ses clients
 - le trafic est routé à un FAI pair ou à un FAI de niveau supérieur
 - le FAI du destinataire route le trafic vers son client destinataire
- mais plus complexe :
 - les AS peuvent être rattachés à plusieurs FAI (*multihoming*)
 - souvent plusieurs chemins possibles

AS : routage hiérarchique



Deux catégories de protocole :

- IGP (*Interior Gateway Protocols*)
 - Routage à l'intérieur d'un AS (basé sur le plus court chemin)
 - RIP-2, EIGRP, IS-IS, **OSPF**
- EGP (*Exterior Gateway Protocols*)
 - Routage entre AS (basé sur les aspects politiques)
 - il n'y en a qu'un : **BGP-4**


ARes : plan du cours 4/5

- 1 La couche réseau
 - Rappels
 - Intégration TCP/IP
 - Structure du paquet IPv4/v6
- 2 Adressage et contrôle
 - Adressage IPv4/IPv6
 - Messages de contrôle
 - Mécanismes associés
- 3 Routage
 - Algorithmes de base et hiérarchie de routage
 - Un protocole de routage interne : OSPF
 - Un protocole de routage externe : BGP

OSPF : *Open Shortest Path First*

- conçut par l'IETF dès 1988 pour :
 - dépasser l'approche de RIP
 - converger rapidement
 - s'adapter aux réseaux de grande taille
 - s'adapter au cas général :
 - LAN (*broadcast*)
 - NBMA
 - point-à-point
 - acquérir la topologie du réseau
 - calculer le plus court chemin sur le graphe associé au réseau
 - être non propriétaire


OSPF : zones (1)



Pour limiter l'impact des changements (échanges, recalculs...)


- zone (*areas*) : sous-parties de l'AS où fonctionne OSPF
 - identificateur sur 32 bits
 - contiguës à un *backbone* (Zone 0)

OSPF : zones (2)




- 3 types de zone :
 - terminale** (*stub area*) sans trafic de transit (Zone 1)
 - pas si terminale** (*NSSA, Not So Stubby Area*)
 - transit** (*transit area*) (Zones 0 et 3)

OSPF : zones (3)



- 3 types de routeur :
 - bordure d'AS** : échange d'info. avec l'extérieur (A et H)
 - frontière de zone** : appartenant à deux zones (B, D et E)
 - interne** : appartenant à 1 zone (C, F et G)


OSPF : routage dans une zone



Diffusion de l'information dans sa zone

- LAN (*broadcast*) : routeur désigné
- **inondation** (ne pas propager une information déjà reçue)
 - les annonces de G sont transmises à D par F inutilement


OSPF : échange entre zone



Annonces entre zones

- Zone 1 reçoit les annonces du *backbone* et de Zone 3 par B
 - B est le routeur par défaut
- Zone 3 reçoit les annonces du *backbone* et de Zone 1 par D et E
 - E permet de choisir D ou E

OSPF : communication avec l'extérieur de l'AS



Echange d'annonces en dehors de l'AS

- information relative à l'accessibilité locale
 - **attention de ne pas transformer le réseau en réseau de transit**

OSPF : protocoles

Version 2 (RFC 2328) incompatible avec OSPF v1

- définition complexe avec plusieurs sous-protocoles
 - **hello** : test des voisins et élection du routeur désigné (LAN)
 - **transfert de base** : synchronisation
 - **mise à jour** : envoi de l'état des liaisons
 - **acquiescement** : confirmation des mises à jours
 - **demande de l'état des liaisons** : connaissance des routeurs de la zone (NBMA)
- encapsulation directe dans un paquet IP (**protocole 89**)
- utilisation du multicast si disponible :
 - 224.0.0.5 ou ff02::5 ➡ tous les routeurs du réseau
 - 224.0.0.6 ou ff02::6 ➡ les routeurs désignés

Version 3 (RFC 5340) support IPv6

ARes : plan du cours 4/5

1 La couche réseau

- Rappels
- Intégration TCP/IP
- Structure du paquet IPv4/v6

2 Adressage et contrôle

- Adressage IPv4/IPv6
- Messages de contrôle
- Mécanismes associés

3 Routage


- Algorithmes de base et hiérarchie de routage
- Un protocole de routage interne : OSPF
- Un protocole de routage externe : BGP

BGP : introduction

Protocole de routage externe de facto

- chronologie des standards :
 - EGP (1984) : RFC 904
 - BGP-1 (1989) : RFC 1195
 - BGP-2 (1990) : RFC 1163
 - BGP-3 (1991) : RFC 1267
 - BGP-4 (1995) : RFC 1771, 1772 et 1773
 - support de CIDR (et IPv6 avec les extensions multi-protocole du RFC 2545)
 - exploitation à grande échelle dès 95 avec la commercialisation d'Internet
- protocole à **vecteur de chemin** :
 - similaire aux protocoles à vecteur de distance
 - permet d'appliquer des contraintes politiques

BGP : topologie





BGP se base sur un ensemble d'AS interconnectés.

- les AS sont représentés par des numéros sur 16 bits
 - attribués par les bureaux d'enregistrement (ARIN, RIPE-NCC...)
 - comme pour les préfixes de réseau
 - env. 50000 attribués (64512 à 65535 privés)

BGP : correspondance AS/réseaux


Un AS ne correspond pas forcément à un réseau

- les *Tier-1* fractionnent souvent leur réseau :
 - ATT : 5074, 6341, 7018...
 - MCI (UUnet) : 284, 701, 702, 12199...
 - Sprint : 1239, 1240, 6211, 6242...
- un numéro d'AS peut être partagé :
 - AS 7046 : Crestar Bank + NJIT + Hood Clg (clients AS 701)



- et de nombreux réseaux d'extrémité n'ont pas besoin de BGP et de numéro d'AS (routage statique en bordure du réseau)


BGP : routeur de frontière



Border Gateway Routers

- passages vers les autres AS
- associés à deux types de connexion :
 - externe (eBGP)
 - interne (iBGP)


BGP : connexions eBGP



exterior BGP

- interconnexion entre AS par les routeurs de frontière
- signalisation BGP sur connexion TCP (port 179) directe


BGP : connexions iBGP



interior BGP

- interconnexion entre les routeurs de frontière dans un AS
- connexion TCP (port 179) routée avec l'IGP de l'AS
- maillage complet (*full mesh*)

BGP : informations échangées



Quelles sont les informations échangées entre AS ?

- principalement les **préfixes** IP et les **chemins** des AS vers ceux-ci

BGP : messages

Seulement 4 messages BGP :

- **OPEN** : ouverture de la connexion
- **KEEPALIVE** : maintien de la connexion
 - envois périodiques
- **NOTIFICATION** : terminaison de la connexion
- **UPDATE** : échange de **préfixes** avec **attributs**
 - toute l'information initialement
 - mise à jours ensuite
 - **announce** (*announcing*) de nouvelles routes
 - **abandon** (*withdrawing*) de route déjà annoncées

BGP : attributs (2)

ORIGIN : d'où provient la connaissance du préfixe


- IGP = vient de l'intérieur de l'AS
- EGP = vient de l'extérieur de l'AS
- INCOMPLETE = configuré manuellement

AS_PATH : suite de numéro d'AS parcouru par l'annonce

- permet de détecter les **boucles**

NEXT_HOP : vers qui orienter le trafic du préfixe annoncé

- dernier routeur de l'AS précédent



BGP : attributs (1)


Value	Code	Reference
1	ORIGIN	[RFC 1771]
2	AS_PATH	[RFC 1771]
3	NEXT_HOP	[RFC 1771]
4	MULTI_EXIT_DISC	[RFC 1771]
5	LOCAL_PREF	[RFC 1771]
...		
8	COMMUNITY	[RFC 1997]
...		
19-254	Unassigned	
255	reserved for development	

Annonce = prefixe + quelques attributs (pas tous)

BGP : attributs (3)

MULTI_EXIT_DISC : lorsqu'il y a plusieurs sorties d'un AS


- **priorité à la valeur la plus petite**



BGP : attributs (4)

LOCAL_PREF : préférence administrative

- **priorité à la valeur la plus élevée**



BGP : algorithme de choix des routes

Strongest to weakest choice criteria :

- 1 highest LOCAL_PREF
- 2 shortest AS_PATH
 - but not necessarily the shortest path
- 3 smallest MULTI_EXIT_DISC
- 4 priority to paths learned via eBGP over iBGP
- 5 shortest path to reach the NEXT_HOP
 - IGP metrics
- 6 smallest router ID

BGP : annonces

Emission d'un message **UPDATE**

- quels préfixes annoncer ?
 - **choix de l'émetteur**
- quelles valeurs d'attribut associer ?
 - dépend de l'attribut
 - AS_PATH = AS_PATH précédent + numéro de l'AS actuel
 - MULTI_EXIT_DISC = dépend du choix de l'émetteur...

Réception d'un message **UPDATE**

- quels informations prendre en compte ?
 - **choix de préfixes** (filtrage)
 - possibilité de modifier les attributs
- que faire des informations acceptées ?
 - **choisir les routes**
 - utilisation d'un algorithme de décision...


BGP : et le choix politique ?

Encore un attribut...

COMMUNITY : permet de "colorier" les routes

- liste de valeurs indiquant à quelles communautés appartient un préfixe
 - 32 bits (16 bits AS colorieur + 16bits au choix)
 - les annonces sont généralement coloriés à l'entrée de l'AS
 - communauté client
 - communauté pair
 - communauté fournisseur
 - permet de **filtrer** à la sortie de l'AS
 - exemple : ne pas injecter les préfixes d'un pair à un autre pair (et ainsi se transformer en AS de transit)


BGP : import de routes



BGP : connectivité


BGP garantit-il la connectivité ?

- **non**, certains réseaux peuvent être injoignables
 - dépend des politiques rencontrées sur le chemin des annonces :



- si "X" n'annonce pas "A" à "B"...

BGP : export de routes



BGP : convergence

BGP garantit-il la convergence pour un routage stable ?

- sans changement, il peut y avoir des oscillations (*route flapping*)
 - un routeur annonce un préfixe puis l'abandonne
 - lié à des liens défaillants
- avec changement, le nombre d'annonces est élevé
 - certains AS peuvent observer plus 10^6 UPDATE par jours

BGP : problèmes

- les erreurs ont une portée globale (sur tout l'Internet)
 - un AS avec une mauvaise configuration peut indiquer qu'il a la meilleur route pour tout les destinataires...
- croissance exponentielle du nombre des annonces
 - de plus en plus d'AS
 - préfixes de plus en plus petits
 - pas d'agrégation à cause du *multihoming*
- supervision complexe
 - le graphe des AS dépend du point de vue
- tentative d'amortissement du *route flapping*
 - utilisation du *route dampening*